

APRENDIZAJE PROFUNDO REDES NEURONALES PROFUNDAS

Primer Cuatrimestre 2025

BACKGROUND ESPERADO

GENERAL

- *Análisis I*
- *Álgebra lineal*
- *Probabilidades y Estadística*

MÁS ESPECÍFICO

- *Conceptos generales de redes neuronales artificiales y conexionismo (un primer curso)*

CONTENIDO DEL CURSO

PRIMERA PARTE

Introducción

- *Las ideas básicas*
- *La controversia*

Modelos basados en energía (energy based models)

- *Redes de memoria asociativa (Modelo de Hopfield)*
- *Máquinas de Boltzmann*
- *Máquina de Boltzmann restringida*
- *Deep Belief Networks*

SEGUNDA PARTE

- *Autoencoders*
- *Redes profundas basadas en autoencoders*
- *Redes Convolucionales*
- *Redes Recurrentes*
- *Embeddings, Word2vec*
- *GAN (generative adversarial networks)*

LAS IDEAS BASICAS

- No es un concepto nuevo, de hecho modelos como el Neocognitron (Fukushima) y el mismo Perceptrón Multicapa ya prefiguran las arquitecturas profundas.
- Algunos autores han “osado” calificar al concepto de deep learning como un *rebranding*.
- Procesamiento no lineal, condición básica que unifica toda la teoría pre- y post DL (si es que esta distinción es legítima).
- Múltiples capas de unidades no lineales (al menos tres)
- Énfasis en la función de cada capa como extractores de características (*feature extractors*), i.e. la información de una capa es procesada y transformada por la siguiente.
- Estructura jerárquica: los distintos niveles de representación constituyen grados crecientes de abstracción, desde los primeros cercanos a la entrada (características básicas de los datos) hasta los últimos (integración en representaciones completas y complejas)

LA CONTROVERSID

¿Buzzword? ¿Re-branding?

POR QUÉ SÍ:

- A partir de c. 2006, nuevo impulso a los modelos fuertemente jerárquicos, en especial por sus resultados prácticos, en tanto que las “viejas redes” habían caído en un cierto descrédito, después de un período de gran interés teórico no acompañado por resultados prácticos acordes.

POR QUÉ NO:

- Las nuevas construcciones arquitectónicas que utilizan las RN “clásicas” para formar jerarquías produjeron saltos que pueden considerarse cualitativos en áreas específicas (imágenes, pattern recognition, procesamiento de lenguaje natural).

REDES PROFUNDAS AVANT LA LETTRE

- Perceptrón multicapa: múltiples niveles de representación pero poco eficiente con arquitecturas profundas (varias capas)*
- Autoencoders*
- Neocognitron (1980, 1ra. versión)*

REDES Y MODELOS ESTADÍSTICOS

GENERATIVAS

Modelo generativo: *distribución de probabilidad conjunta $P(X, Y)$*

X variable observable, Y variable objetivo

generan variables observables y objetivo, calculables a partir de las observadas

→ generación de instancias aleatorias de una observación $x \rightarrow P_{\text{modelo}} \sim P_{\text{datos}}$

Principal aplicación: *generación de datos*

Ejemplo típico: *GAN (generative adversarial networks)*

DISCRIMINATIVAS

Modelo discriminativo: *distribución de probabilidad condicional $P(Y/X=x)$*

Y variable objetivo, X variable observada

sólo modelan las variables objetivo, en base a las observables


→ discriminación del valor de Y dada una observación x

Principal aplicación: *clasificación de datos*

Ejemplo típico: *Redes Convolucionales*


DEEP BELIEF NETWORKS

Estructura general:

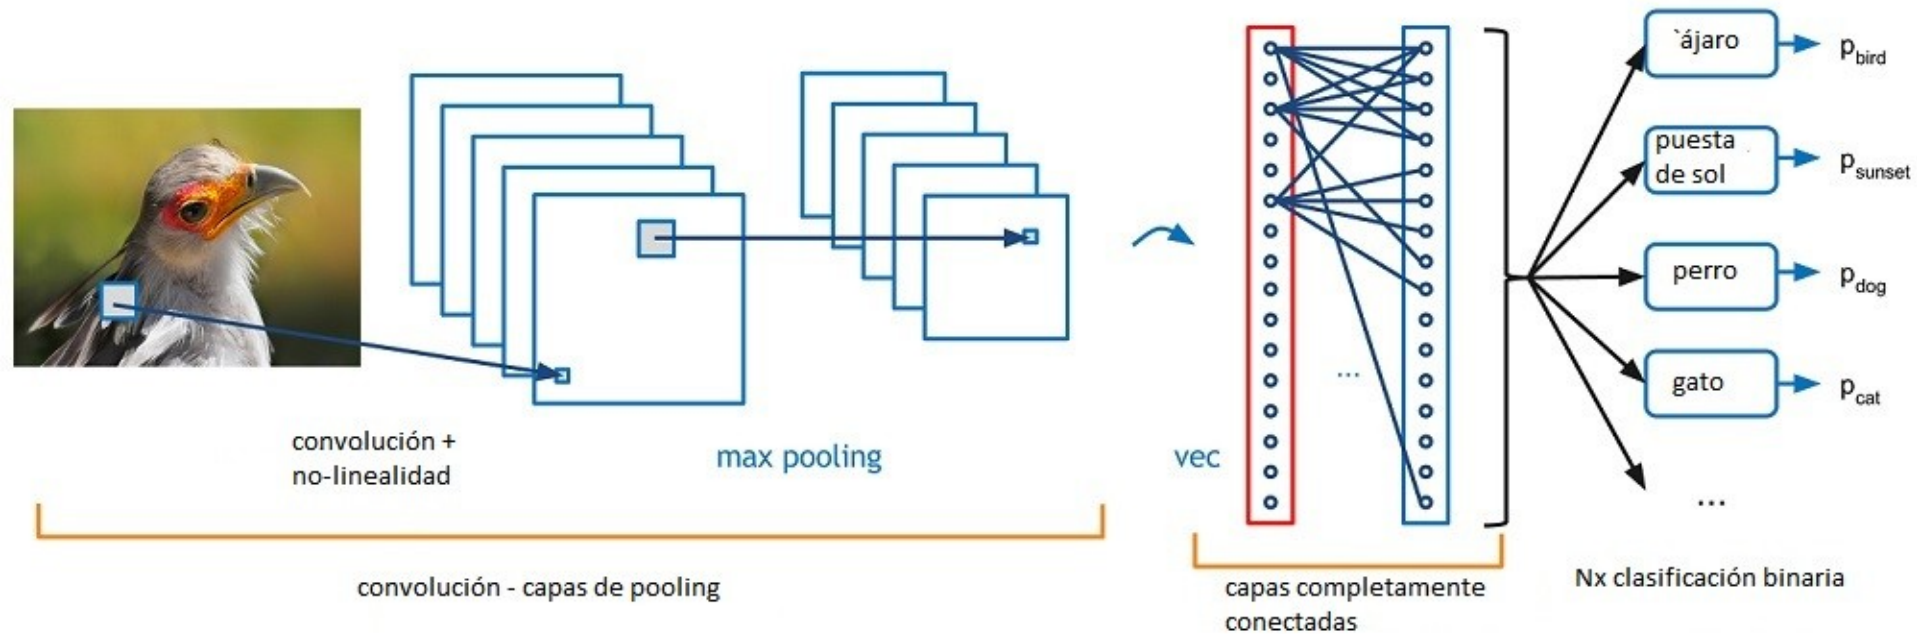


- RBM's apiladas, con conexiones dirigidas
- Última capa: memoria asociativa, conexiones no dirigidas

AUTOENCODER



REDES CONVOLUCIONALES



BIBLIOGRAFÍA

General

Goodfellow I., Bengio Y. y Courville, A., Deep Learning, MIT Press, 2016.

Arquitecturas profundas

- Salakhutdinov R. y Hinton G.E.; Deep Boltzmann Machines; AISTATS, 448-455 (2009)
- Bengio Y. y Courville, A.; Deep Learning of Representations, capítulo en Handbook on Neural Information processing; Bianchini, M., Jain, L., Maggini, M., Eds.; Springer:Berlin Heidelberg (2011)
- Bengio Y.; Learning Deep Architectures for AI; Foundations and Trends in Machine Learning, vol. 2, 1:1-127 (2009).

Autoencoders

- Rumelhart D.E., Hinton G.E. y Williams R.J.; Learning representations by back-propagating errors; Nature, vol. 323, 533-536 (1986)
- Olshausen B.A. y Field D.J.; Emergence of simple-cell receptive field properties by learning a sparse code for natural images; Nature, vol. 381, 607-609 (1996)
- Liou C-Y., Cheng W-C., Liou J-W. y Liou D-R.; Autoencoder for words; Neurocomputing vol.139, 84-96 (2014)
- Vincent P., Larochelle, H., Lajoie, I., Bengio, Y. y Manzagol, P-A.; Stacked Denoising Autoencoders: Learning Useful Representations in a Deep Network with a Local Denoising Criterion: The Journal of Machine Learning Research. 11:3371–3408 (2010)

Redes Convolucionales

- LeCun Y., Boser B., Denker J.S., Henderson D., Howard R.E., Hubbard W. y Lawrence L.D.; Backpropagation applied to handwritten zip code recognition; Neural Computation 1, 541-551 (1989)
- LeCun, Y. y Bengio, Y. Convolutional networks for images, speech, and time series; The handbook of brain theory and neural networks, 3361 (1995)
- Eigen D., Rolfe J., Fergus R. y LeCun Y.; Understanding Deep Architectures using a Recursive Convolutional Network; International Conference on Learning Representations (ICLR2014), CBLS (2014).

Redes Recurrentes

- Elman J.L.; Finding Structure In Time, Cognitive Science, **14**:179-211 (1990)
- Hochreiter, S. y Schmidhuber, J.; Long short-term memory. *Neural computation*, **9(8)**: 1735-1780 (1997)
- Sutskever, I.. Training recurrent neural networks (Doctoral dissertation, University of Toronto) (2013)

Máquinas de Boltzmann

- Kappen H.J.; Deterministic learning rules for Boltzmann Machines; Neural Networks, vol. 8, 537-548 (1995)
- Hinton G.E.; Learning multiple layers of representation; TRENDS in Cognitive Sciences, vol.11, 10:428-434 (2007)

Generative Adversarial Networks

- Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., Bengio, Y.; Generative Adversarial Nets; Proc. Int. Conf. on Neural Information Processing Systems (NIPS 2014). pp. 2672–2680. (2014)

Embeddings

- Mishra, M.K y Viradiya, J.; Survey of sentence embedding methods. Int. J. Applied Science and Computations vol. 6.nro.3, 592592 (2019)

- Reimers, N. y Gurevych, I.; "Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks." Proc.2019 Conf. on Empirical Methods in Natural Language Processing / 9th International Joint Conf. on Natural Language Processing (EMNLP-IJCNLP), pp. 3982-3992. (2019).